Обучаемый граф и message passing: как структура связей помогает обучению

Воронов Д. А., ИУ9-72Б

План

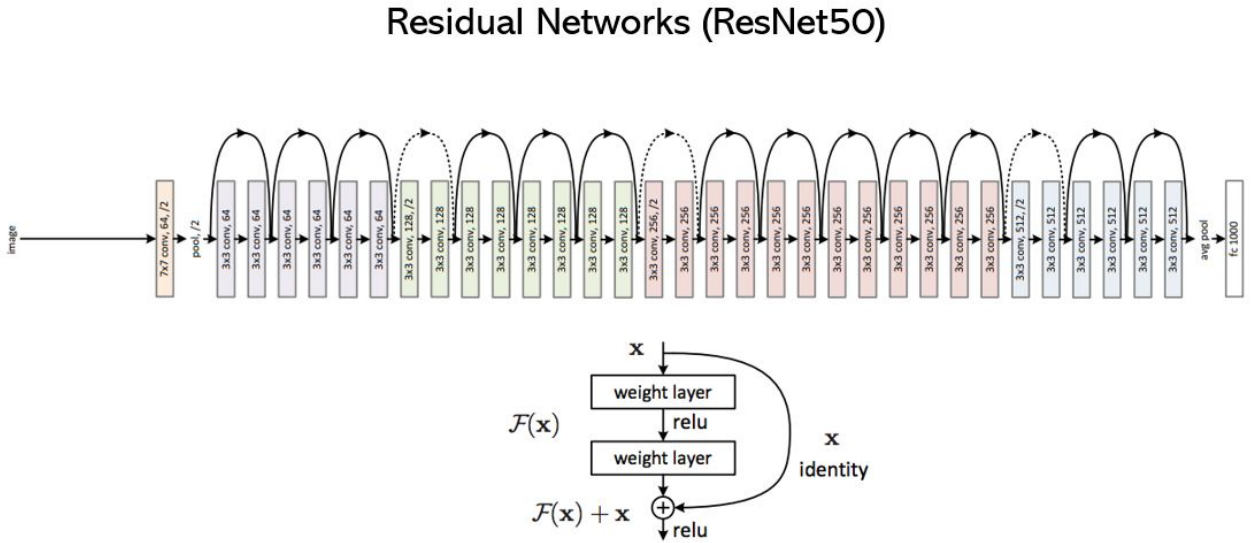
1. Проблема статичных архитектур.
2. Обучаемый граф помогает обучению.
3. message passing — механизм.

Определение статичной архитектуры

Статичная архитектура — это такая архитектура, модель которой имеет фиксированный вычислительный граф и параметры которой никак не меняются во время обучения.

Формально: $y=F(x,a)$, где a фиксирован.

Пример статичной архитектуры



Все примеры будут обрабатываться одинаково!

Проблемы статичных архитектур

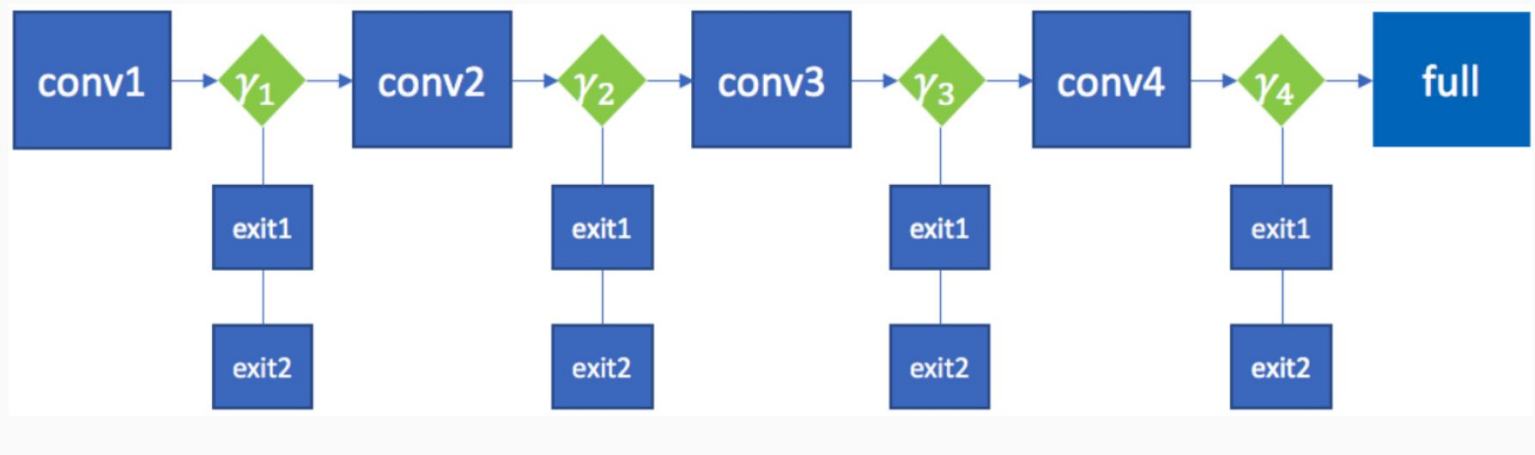
1. Неэффективное использование вычислений
2. Невозможность узнать влияние признака на результат (слабая интерпретируемость)
3. Невозможность выучить тонкие различия между классами

Динамические системы

Основные механизмы:

1. Работаем в начале с наиболее простыми примерами.
2. Активируются не все каналы, а только нужные.
3. Из сети выбирается только один путь

То есть динамика будет **адаптироваться под вход**

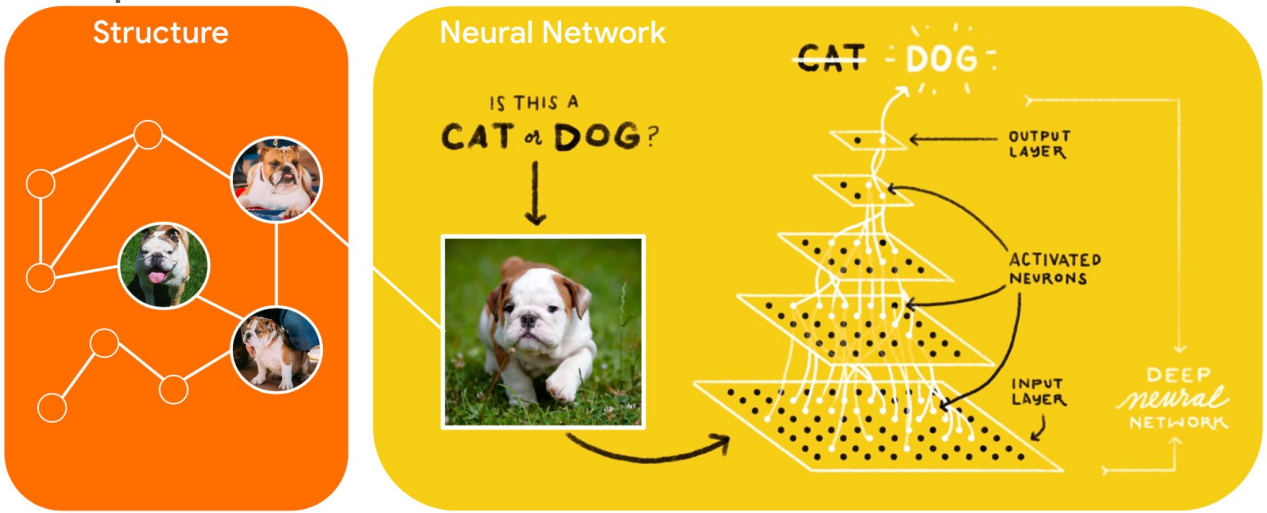


Пример: Система досрочного выхода для AlexNet [1]

Обучаемый граф помогает обучению

При обучении используем не только сами признаки объектов, но и структурные сигналы.

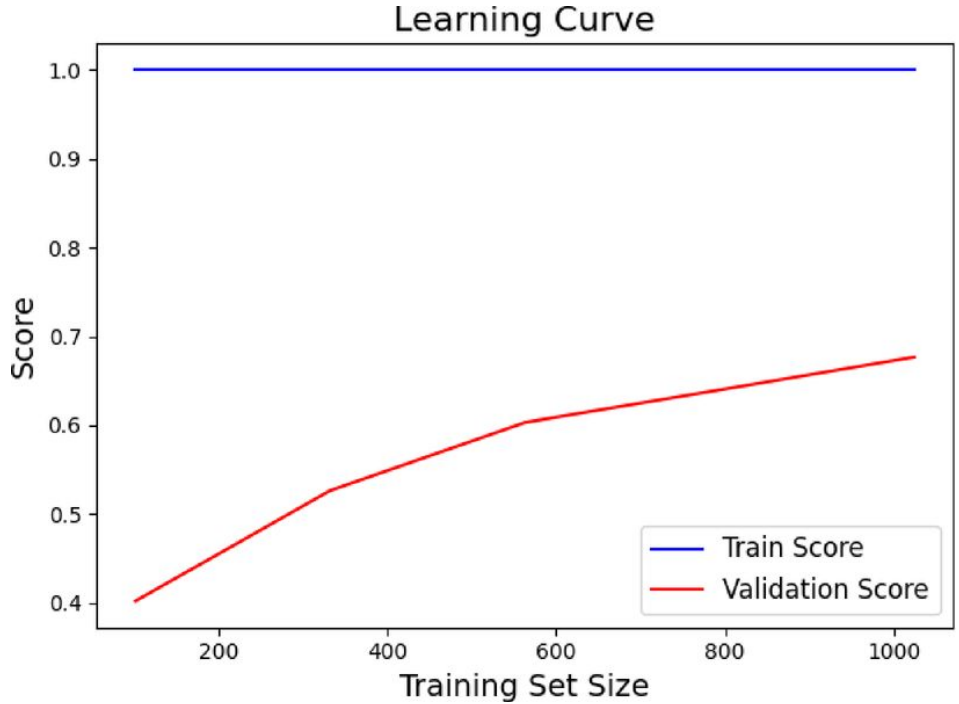
Структурные сигналы — это отдельный от признаков поток информации, но идет рядом с признаками.



Использование графа при малой разметке

Структура даёт дополнительный сигнал через связи.

С уменьшением числа размеченных примеров будет расти вклад структуры.



Пример проблемы в обучении при малой разметке [2]

Как работает message passing

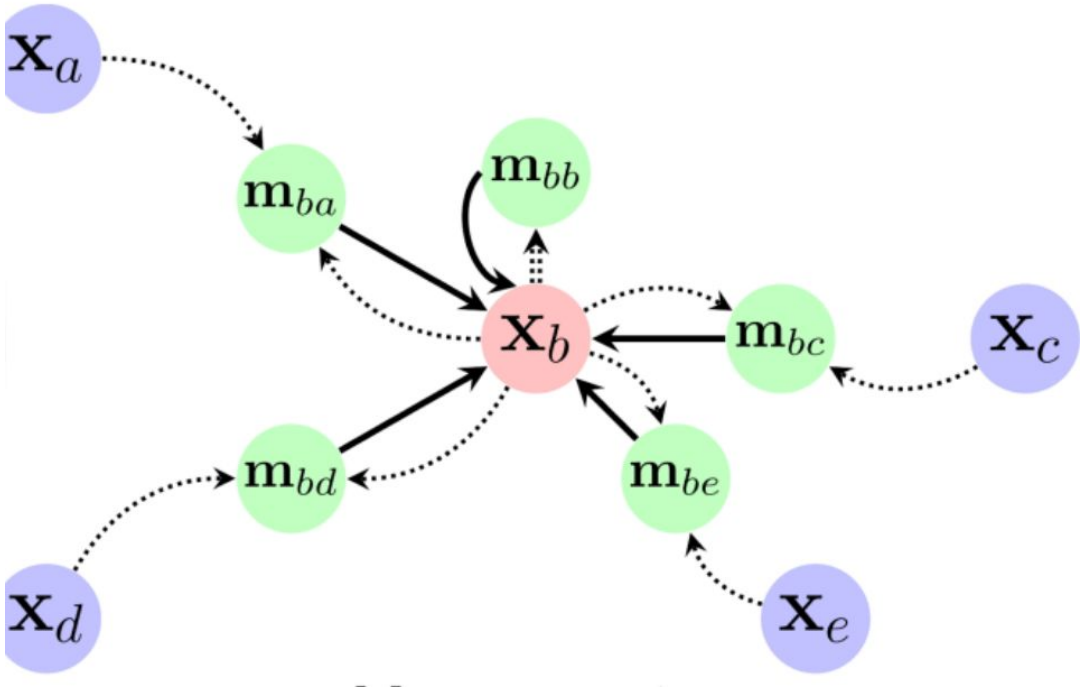
Вход: ребра графа и признаки его узлов

$$m_{u \to v} = \text{MESSAGE}\left(h_u^{(k)}\right)$$

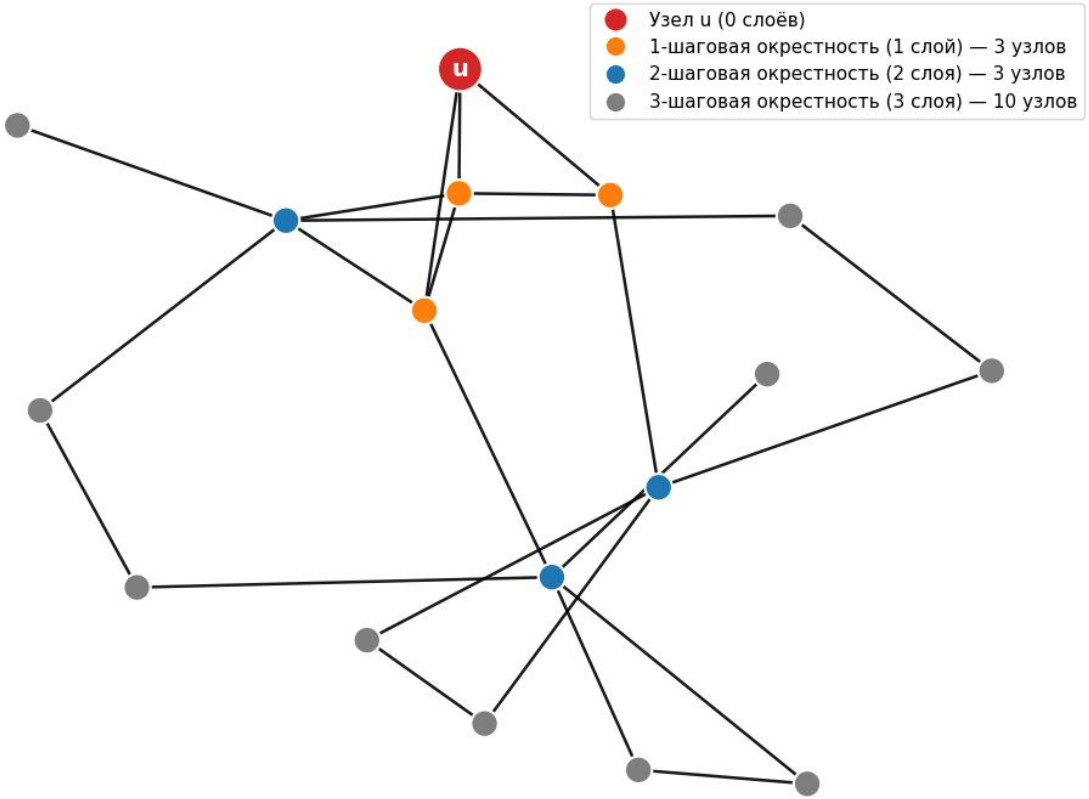
$$M_v = \bigoplus_{u \in \mathcal{N}(v)} m_{u \to v}$$

$$h_v^{(k+1)} = \text{UPDATE}\left(h_v^{(k)}, M_v\right)$$

Выход: обновленное представление узла, учитывающее информацию о его окружении



Многослойный message passing



Свойства message passing.

1. Инвариантность относительно порядка узлов.
2. При слишком большом числе слоев представления узлов сглаживаются и становятся похожими.
3. Полнота представления: представление состоит не только из признаков, но и из своего окружения.

Эксперимент

Проверить, как поможет граф при обучении, когда разметки мало.

Гипотеза: Наибольшая польза от графа будет при малой разметке. Графовый автоэнкодер дополнительно использует структуру связей через message passing. Это позволяет ему выучить более информативные представления, в которых классы уже частично разделены.

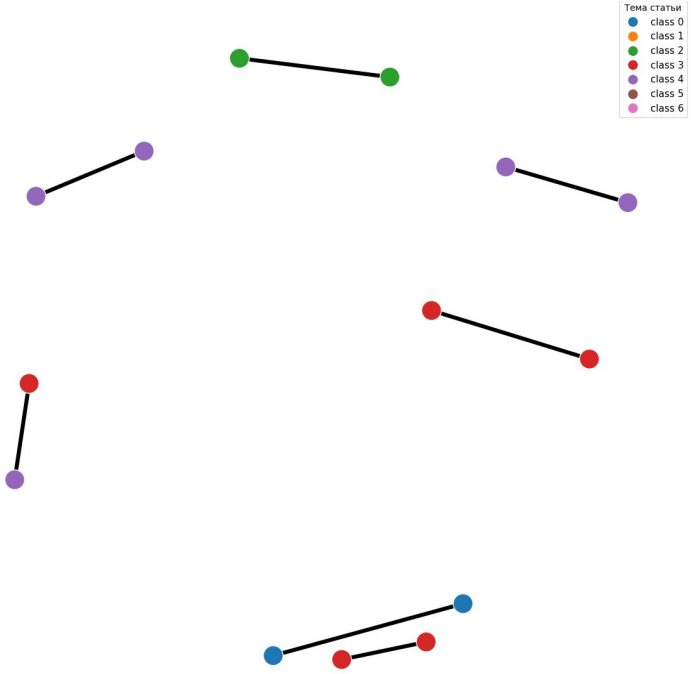
Датасет для эксперимента

Датасет Cora: граф цитирований научных статей.

Объект – научные статьи.

В качестве узлов графа – статьи (2708 статей), а в качестве ребер – цитирования, их 10556 (связей «статья А цитирует статью В»). Признаками являются слова статьи. И каждая статья относится к одному из 7 классов.

Цель обучения: предсказать тему статьи по ее признакам и связям.



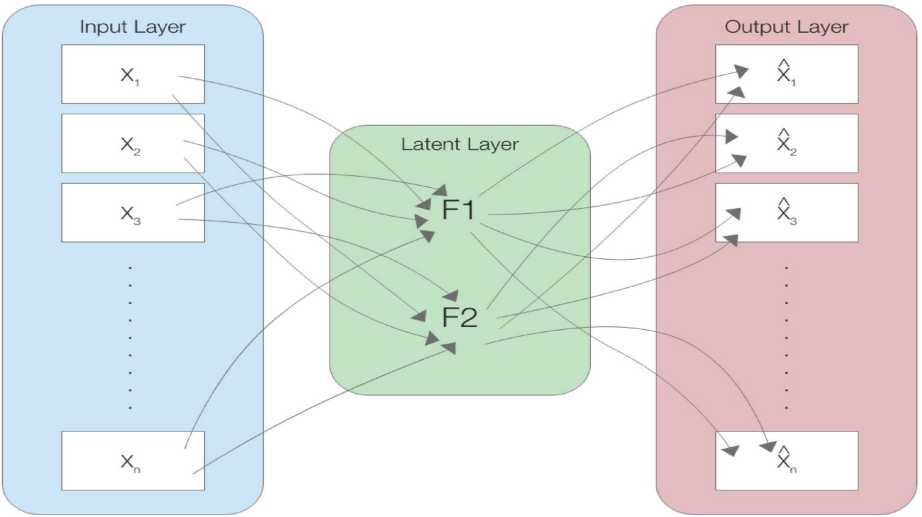
Оценка качества

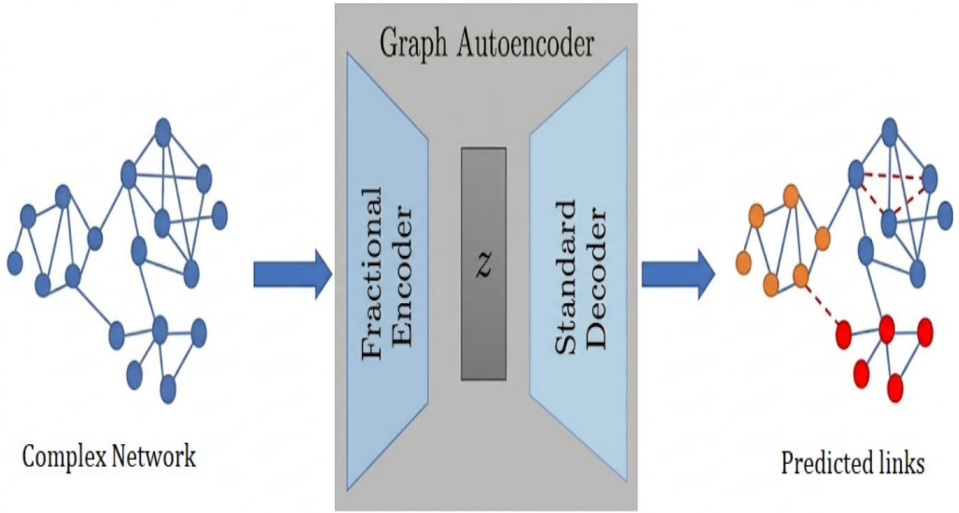
Метрика – Accuracy, то есть доля правильных ответов. Была выбрана ввиду сбалансированности классов датасета.

Также произведем измерения времени обучения для обычного и графового автоэнкодеров, чтобы проверить насколько дольше будет проходить обучение уже с использованием графовой структуры.

Реализация эксперимента

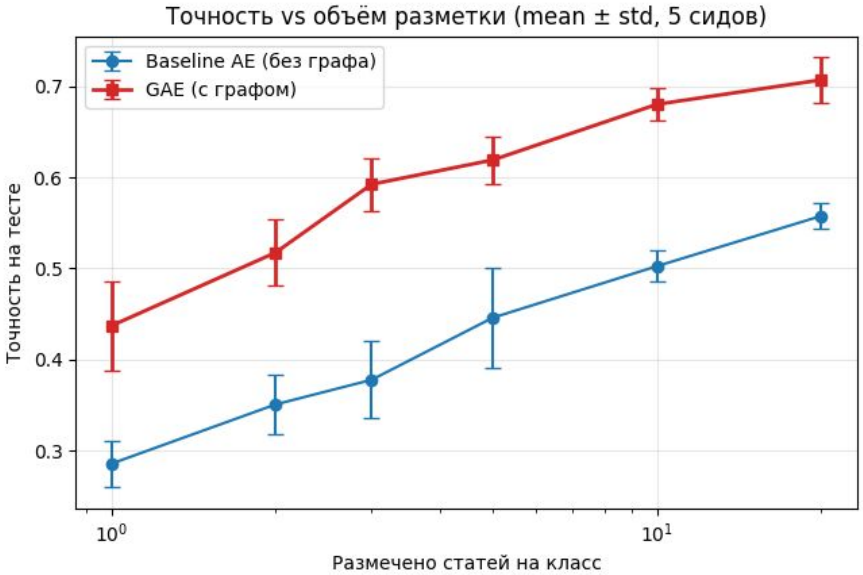
1. Фиксируем объем данных для обучения.
2. Обучаемый базовый автоэнкодер и графовый автоэнкодер.
3. Оцениваем получившиеся accuracy и время выполнения

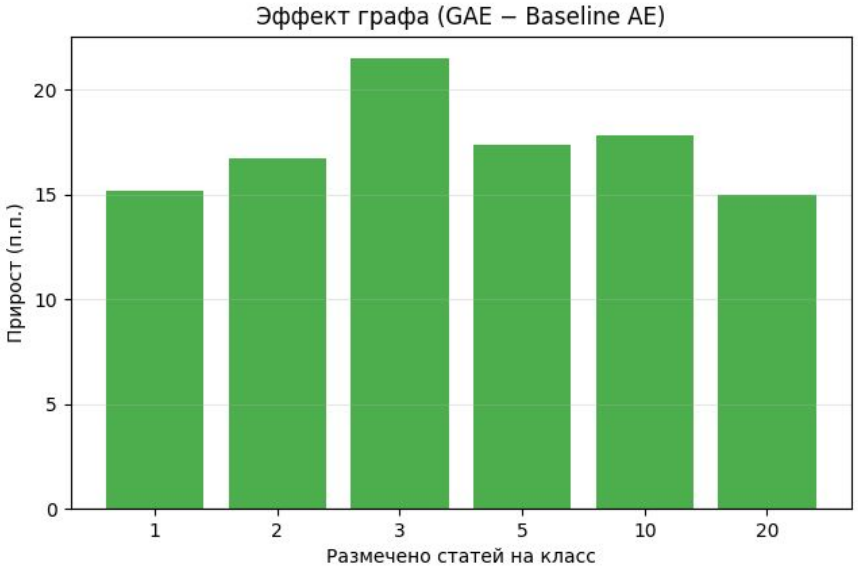




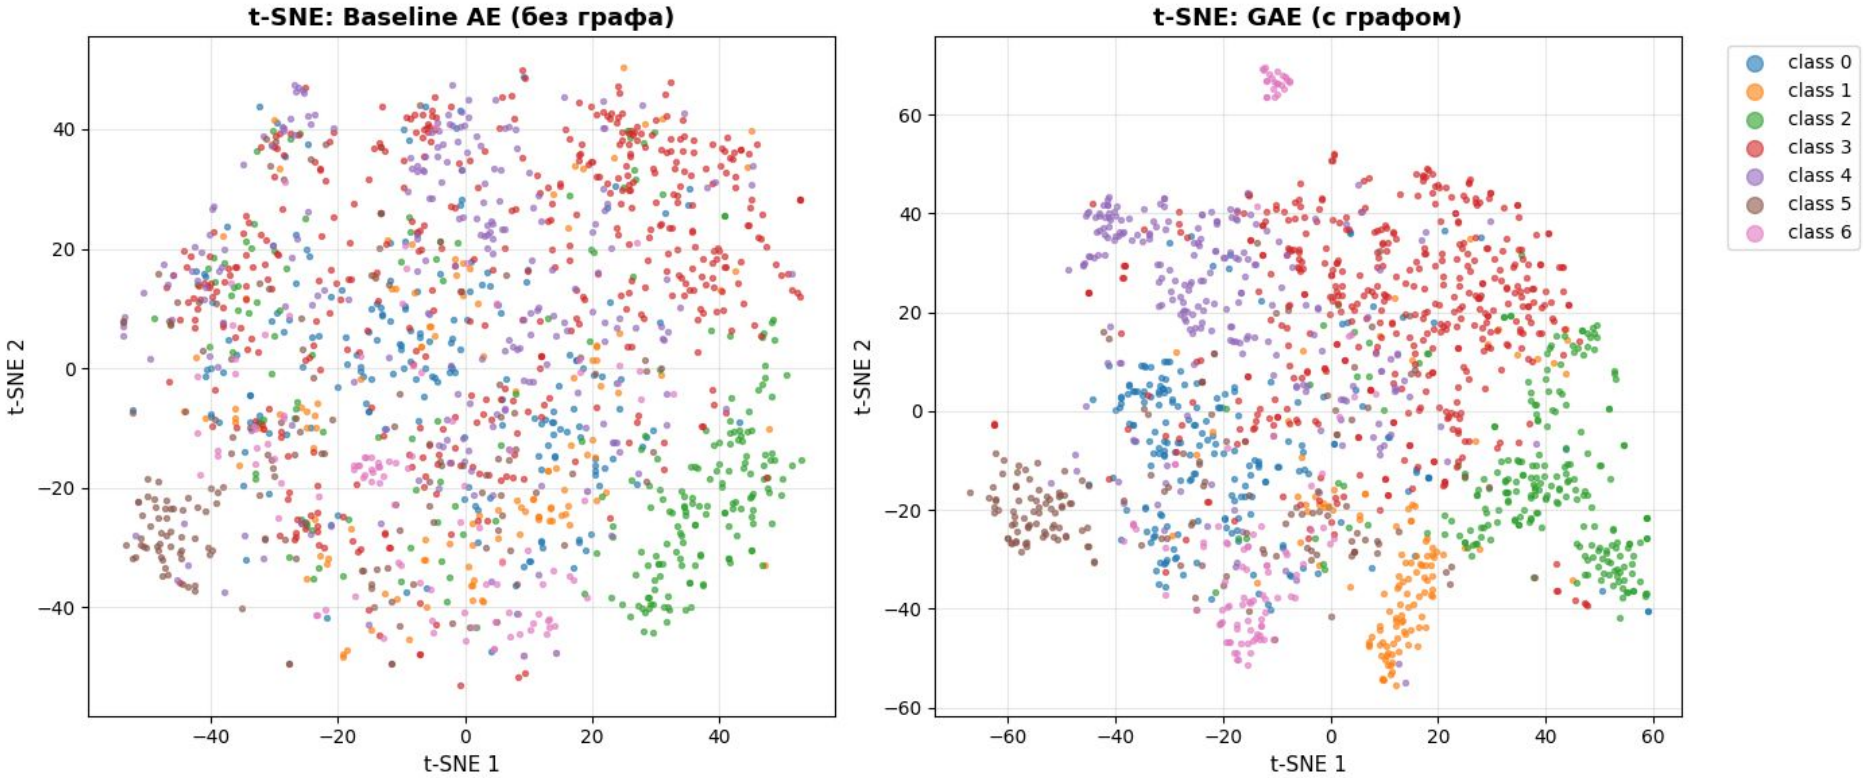
Результаты

GAE: 29.5 сек, Baseline прогон: 24.7 сек.





Результаты


t-SNE: Baseline AE (без графа)
t-SNE: GAE (с графом)
t-SNE 1
t-SNE 2
class 0
class 1
class 2
class 3
class 4
class 5
class 6

Источники

1. Tolga Bolukbasi, Joseph Wang, Ofer Dekel, and Venkatesh Saligrama. Adaptive neural networks for efficient inference. In International Conference on Machine Learning, pages 527–536. PMLR, 2017.
2. Assessing random forest performance in low resource speech emotion recognition: https://www.nature.com/articles/s41598-025-30511-6
3. Dynamic Neural Networks: A Survey: https://arxiv.org/pdf/2102.04906
4. Обучение с помощью структурированных сигналов: https://tensorflow.google.cn/neural_structured_learning?hl=ru
5. GDL Course: https://geometricdeeplearning.com/lectures/